ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
“САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ”
(СПбГУ)

Образовательная программа бакалавриата “Математика”

Отчет о практике

на тему

Sequential модификация метода Flow Matching Posterior Estimation

Выполнил студент 2 курса бакалавриата
группа 24.Б03-мкн
Ураков Михаил Алексеевич

Научный руководитель:
Должность, ФИО

Санкт-Петербург
2026

Содержание

1. Введение 3
2. Flow Matching 4
2.1. Ключевая идея Flow Matching 6
2.2. Условная формулировка 6
2.3. Пример 6
2.4. Теорема о совпадении лоссов 7
3. Последовательные методы 8
3.1. NPE-A,B,C 8
3.2. Truncated 8
4. Основные результаты 8
4.1. Gaussian Mixture 8
4.2. SIR 9
4.3. Модель Хестона 9
5. Послесловие 9
6. Формулировка основных результатов 10
7. Методы доказательства 10
Список литературы 10

1. Введение

Задача оценки истинных параметров математической модели встречается во многих научных и прикладных областях: генетике [fast-eps-source], физике [DINGO-source], финансах и др. Она становится особенно сложной, когда невозможно аналитически описать распределение наблюдений при заданных параметрах. В этой работе я, следуя статье [DINGO-source], предлагаю модификацию метода Flow Matching Posterior Estimation и сравниваю его с другими методами на простых задачах, а в конце применяю его для оценки параметеров модели стохастической волатильности.

С математической точки зрения наша задача формулируется следующим образом. Будем обозначать $\theta \in \mathbb{R}^m$ — вектор параметров модели, а $x \in \mathbb{R}^n$ — наблюдаемые/симулированные данные или, чаще, их малоразмерная аппроксимация, выжимка. Из-за стохастической природы моделей удобно считать как x, так и θ случайными величинами.

Далее, нам известно, возможно неявно, *правдоподобие* $p(x \mid \theta)$ - распределение наблюдений x, которые мы можем получить при условии, что модель инициализирована параметрами θ. Также мы имеем вольность задать *априорное* распределение $p(\theta)$ - наше общее представление о том, в каких пределах могут изменяться параметры модели.

Имея все это, мы хотим узнать *апостериорное* распределение $p(\theta \mid x)$ — распределенине параметров, которые могли бы дать нам такое же наблюдение x. Тогда по формуле байеса имеем

$$p(\theta \mid x) = \frac{p(x \mid \theta)p(\theta)}{p(x)}$$

Markov Chain Monte Carlo. Таким образом, коль скоро нам известны $p(x \mid \theta), p(\theta)$, можно считать, что $p(\theta \mid x) \propto p(x \mid \theta)p(\theta)$. Если бы мы имели аналитическое выражение для последнего, то могли бы сэмплировать из апостериорного распределения методами Markov Chain Monte Carlo (MCMC, [**?**]). Их суть заключается в том, чтобы построить марковскую цепь, стационарное распределение которой будет совпадать с заданным. Тогда, пройдя по ней достаточное число шагов, мы получим выборку из нужного распределения.

Помимо того, что нам нужно знать явное выражение для ненормированной плотности, у этого метода есть другие минусы, такие как: вычислительная затратность, сложность диагностики сходимости, чувствительность к настройкам и проблемы в больших размерностях.

Approximate Bayesian Computation. В случае когда мы не можем аналитически выразить правдоподобие, приходится действовать другими методами. В литературе их объединяют под общим названием ABC (Approximate Bayesian Computation [**?**]) методов. Классические алгоритмы ABC основаны на предоположении о том, что если наблюдения похожи, то и соответствующие параметры тоже. Более формально, они аппроксимируют истинное апостериорное $p(\theta \mid x_o)$ с помощью $p(\theta \mid |x_o - x| < \varepsilon)$

Самый простой метод, Rejection ABC, работает так:

(1) Дано: наблюдение x_o, хотим получить выборку из $p(\theta \mid x_o)$
(2) Генерируем $\theta^* \sim p(\theta)$
(3) Симулируем $x \sim p(x \mid \theta^*)$
(4) Если $|x_o - x| < \varepsilon$, то добавляем θ^* в выборку, иначе повторить 2.

Из очевидных минусов — это проклятие размерности и неэффективность вычислений. Для вычисления апостериора только в одной точке x_o нам требуется провести тысячи

симуляций, большая часть из которых будет отметена, причем с увеличением размености это число растет экспоненциально.

Neural Posterior Estimation. В последние годы, с развитием машинного обучения, пришли и новые методы оценки апостериора. В отличие от классических алгоритмов, где апостериор вычислялся только эмпирически, методы NPE (Neural Posterior Estimation, [**?**]) позволяют аппроксимировать функцию плотности с помощью нейросети. Часто в качестве универсального аппроксиматора используют *нормализующие потоки* (Normalizing Flows, [**?**]), хорошо показавшие себя в задачах физики гравитационных волн [**?**]. Нормализующие потоки отображают сэмплы из одного (обычно, гауссовского) распределения в другое распределение серией последовательных несложных преобразований, параметризованых нейросетью.

Минус такого подхода в том, что эти преобразования должны быть обратимы и иметь определенный вид чтобы сеть можно было эффективно обучать. К тому же, такая архитектура плохо масштабируема для нужд больших и сложных экспериментов.

Однако, самый большой и главный плюс в сравнении с классическими методами — это то, что теперь, у нас на выходе не просто выборка из нужного распределения, а функция, которая каждому наблюдению x сопоставляет распределение $p(\theta \mid x)$. Таким образом, один раз обучив такую модель, мы получим $p(\theta \mid x)$ для всех возможных x, а не только одного — в литературе это называется амортизированным инференсом (Amortized Inference, [**?**]).

В контексте отображения одного распределения в другое эта задача родственна задаче генеративного ИИ. А в последние годы, в этой области доминируют диффузионные модели [**?**]. Принцип их работы основан на том же преобразовании одного распределения в другое, только теперь сэмплы двигаются по траекториям, которые являются решениями СДУ, заданного векторным полем. И нейросетью здесь параметризовано это самое поле.

Детерминированным аналогом диффузионных моделей являются Flow Matching модели [**?**]. В данном случае, вместо стохастического дифференциального уравнения используется обыкновенное. На них мы и сосредоточимся в этой работе.

2. Flow Matching

Я изложу основные идеи метода Flow Matching и приведу доказательства некоторых утверждений Пусть:

- $p_0(x)$ — простое распределение (например, $\mathcal{N}(0, I)$),
- $p_1(x)$ — целевое распределение данных.

Задача: построить диффеоморфизм

$$\psi_1 : \mathbb{R}^d \to \mathbb{R}^d,$$

такой что

$$p_1(x) = [\psi_1]_{\#} p_0(x) = p_0(\psi_1^{-1}(x))|\partial_x \psi_1^{-1}(x)|$$

Т.е. $X_1 = \psi_1(X_0) \sim p_1 \iff X_0 \sim p_0$. Вместо того, чтобы строить ψ_1 напрямую, рассмотрим векторное поле

$$\frac{d}{dt}\psi_t(x) = v_t(\psi_t(x)), \quad t \in [0, 1].$$

Из которого отображение ψ_1 восстанавливается интегрированием

$$\psi_1(x) = p_0(x) + \int_0^1 v_t(\psi_t(x))dt$$

Теорема 1.

Предложение 1. *Если ψ_t удовлетворяет*

$$\frac{d}{dt}\psi_t(x) = v_t(\psi_t(x)),$$

то плотность $p_t = [\psi_t]_\# p_0(x)$ удовлетворяет уравнению непрерывности:

$$\partial_t p_t(x) + \nabla \cdot \big(p_t(x) v_t(x)\big) = 0.$$

Тогда, если мы найдём правильное v_t, то ψ_t *хорошим образом* перенесёт p_0 в p_1

Доказательство. Поскольку $\rho_t(y)$ определено как

$$\rho_t(y) = (\psi_t)_\# \rho_0(y) = \rho_0(\psi_t^{-1}(y))|\det \partial_y \psi_t^{-1}(y)|$$

то

$$\int \varphi(y)\,\rho_t(y)\,dy = \int \varphi(\psi_t(x))\,\rho_0(x)\,dx \quad \forall \varphi \in C_c^\infty.$$

Продифференцируем обе части по t:

$$\frac{d}{dt}\int \varphi(\psi_t(x))\,\rho_0(x)\,dx = \int \frac{d}{dt}\varphi(\psi_t(x))\,\rho_0(x)\,dx$$

$$\frac{d}{dt}\varphi(\psi_t(x)) = \nabla\varphi(\psi_t(x)) \cdot \dot{\psi}_t(x).$$

И т.к.

$$\dot{\psi}_t(x) = u_t(\psi_t(x)),$$

получим

$$\frac{d}{dt}\int \varphi(\psi_t(x))\,\rho_0(x)\,dx = \int \nabla\varphi(\psi_t(x)) \cdot u_t(\psi_t(x))\,\rho_0(x)\,dx$$

Снова, по определению $\rho_t(y)$

$$\int \nabla\varphi(\psi_t(x)) \cdot u_t(\psi_t(x))\,\rho_0(x)\,dx = \int \nabla\varphi(y) \cdot u_t(y)\,\rho_t(y)\,dy$$

Интегрированием по частям получим

$$\int \nabla\varphi \cdot u_t \rho_t = -\int \varphi\,\nabla \cdot (\rho_t u_t)$$

Тогда

$$\frac{d}{dt}\int \varphi\rho_t + \int \varphi\,\nabla \cdot (\rho_t u_t) = 0$$

И посольку это выполнено для всех φ, то

$$\partial_t \rho_t + \nabla \cdot (\rho_t u_t) = 0$$

в слабом смысле $\square$

2.1. **Ключевая идея Flow Matching.**

Вместо обучения напрямую распределения $q_\theta(x) \approx p_1(x)$ через KL-дивергенцию, Flow Matching предлагает:

(1) Задать интерполирующее распределение p_t между p_0 и p_1
(2) Вычислить соответствующее *истинное* поле скоростей $u_t(x)$.
(3) Обучать модель v_θ по регрессии:

$$\mathcal{L}_{\mathrm{FM}} = \mathbb{E}_{t\sim U[0,1],\, x\sim p_t} \|v_t^\theta(x) - u_t(x)\|^2.$$

Проблема лишь в том, что *истинное* поле $u_t(x)$ нам обычно неизвестно.

2.2. **Условная формулировка.**

Тогда, вместо маргинального полея $u_t(x)$ введем условное поле

$$u_t(x \mid z),$$

где z — латентная случайная величина (например, пара $z = (x_0, x_1) \sim \pi_{0,1}$). Тогда условный лосс:

$$\mathcal{L}_{\mathrm{cond}} = \mathbb{E}_{t,z,x_t\sim p_{1|z}(\cdot|z)} \|v_t^\theta(x_t) - u_t(x_t \mid z)\|^2.$$

И это легко сэмплировать:

(1) берём z,
(2) генерируем $x_t \sim p_{1|z}$,
(3) знаем $u_t(x_t \mid z)$ аналитически

В таком случае истинное поле выражается как

$$u_t(x) = \mathbb{E}_{z\sim\pi}\big[u_t(X_t \mid z) \mid X_t = x\big].$$

2.3. **Пример.**

Простейший случай с двумя гауссианами

$$\begin{aligned} p_0(x) &= \mathcal{N}(\mu_0, \sigma_0) \\ p_1(x) &= \mathcal{N}(\mu_1, \sigma_1) \\ \psi_{t|1}(x \mid x_1) &= tx_1 + (1-t)x \end{aligned}$$

Тогда условное поле скоростей:

$$u_{t|1}(x \mid x_1) = \dot{\psi}_{t|1} \circ \psi_{t|1}^{-1}(x \mid x_1) = \frac{x_1 - x}{1-t}$$

И условный probability path:

$$p_{t|1}(x \mid x_1) = p_{0|1}(\psi_{t|1}^{-1}(x \mid x_1))|\partial_x \psi_{t|1}^{-1}(x \mid x_1)| =$$

$$= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{\frac{x-tx_1}{1-t}-\mu_0}{\sigma_0}\right)^2} \cdot \frac{1}{1-t} = \mathcal{N}(tx_1 + (1-t)\mu_0, (1-t)\sigma_0)$$

Тогда marginal probability path:

$$p_t(x) = \int p_{t|1}(x|x_1)p_1(x_1)dx_1 =$$

$$= \int \mathcal{N}(tx_1 + (1-t)\mu_0, (1-t)\sigma_0)\,\mathcal{N}(\mu_1, \sigma_1)dx_1 =$$

$$= \mathcal{N}(t\mu_1 + (1-t)\mu_0, t^2\sigma_1 + (1-t)\sigma_0)$$

Отсюда по формуле Байеса

$$p_{1|t}(x_1 \mid x) = \frac{p_{t|1}(x \mid x_1)p_1(x_1)}{p_t(x)} = \mathcal{N}(\mu_{1|t}(x), \sigma_{1|t}(x))$$

где

$$\mu_{1|t}(x) = \mu_1 + \frac{t\sigma_1(x - t\mu_1 - (1-t)\mu_0)}{t^2\sigma_1 + (1-t)\sigma_0}$$

$$\sigma_{1|t}(x) = \frac{\sigma_1(1-t)\sigma_0}{t^2\sigma_1 + (1-t)\sigma_0}$$

Итого, marginal velocity field:

$$u_t(x) = \int u_{t|1}(x \mid x_1)p_{1|t}(x_1 \mid x)dx_1 =$$

$$= \mathbb{E}\Big[\frac{X_1 - X_t}{1-t} \mid X_t = x\Big] = \frac{1}{1-t}\mathbb{E}[X_1 \mid X_t = x] - \frac{x}{1-t} =$$

$$= \frac{\mu_{1|t}(x) - x}{1-t}$$

2.4. **Теорема о совпадении лоссов.**

Теорема 2. [?]

Градиент условного лосса совпадает с градиентом маргинального лосса:

$$\nabla_\theta \mathcal{L}_{cond} = \nabla_\theta \mathcal{L}_{marg},$$

где

$$\mathcal{L}_{cond} = \mathbb{E}_{t, Z\sim\pi, X_t\sim p_{1|Z}} \|v_t^\theta(X_t) - u_t(X_t|Z)\|^2.$$

$$\mathcal{L}_{marg} = \mathbb{E}_{t, X_t\sim p_t} \|v_t^\theta(X_t) - u_t(X_t)\|^2$$

Доказательство. [?]

$$
\begin{aligned}
\nabla_\theta \mathcal{L}_{\text{marg}} &= \nabla_\theta \mathbb{E}_{t,X_t} \|v_t^\theta(X_t) - u_t(X_t)\|^2 \\
&= \mathbb{E}_{t,X_t} \nabla_\theta \|v_t^\theta(X_t) - u_t(X_t)\|^2 \\
&= \mathbb{E}_{t,X_t} \nabla_\theta v_t^\theta(X_t) \nabla_{v_t^\theta} \|v_t^\theta(X_t) - u_t(X_t)\|^2 \\
&= \mathbb{E}_{t,X_t} \nabla_\theta v_t^\theta(X_t) \nabla_{v_t^\theta} \|v_t^\theta(X_t) - \mathbb{E}_{Z\sim p_{Z|t}}[u_t(X_t \mid Z)]\|^2 \\
&= \mathbb{E}_{t,X_t} \mathbb{E}_{Z\sim p_{Z|t}} \nabla_\theta v_t^\theta(X_t) \nabla_{v_t^\theta} \|v_t^\theta(X_t) - u_t(X_t \mid Z)\|^2 \\
&= \mathbb{E}_{t,X_t} \mathbb{E}_{Z\sim p_{Z|t}} \nabla_\theta \|v_t^\theta(X_t) - u_t(X_t \mid Z)\|^2 \\
&= \mathbb{E}_{t,X_t\sim p_{t|Z},Z\sim\pi} \nabla_\theta \|v_t^\theta(X_t) - u_t(X_t \mid Z)\|^2 \\
&= \nabla_\theta \mathbb{E}_{t,X_t\sim p_{t|Z},Z\sim\pi} \|v_t^\theta(X_t) - u_t(X_t \mid Z)\|^2 \\
&= \nabla_\theta \mathcal{L}_{\text{cond}}
\end{aligned}
$$

□

3. Последовательные методы

Зачастую, нам требуется не просто оценить апостериор для данного x, а сделать это хорошо и эффективно. В таком случае, в существующие методы можно ввести некоторые модификации. Например, для Rejection ABC после некоторого числа подходящих сэмплов, логично предположить, что все последующие будут находится в пределах нынешней выборки $\{\theta_i\}_{i=1}^n$, т.е. распределение $p(\theta \mid |x_o - x| < \varepsilon)$ можно представить как возмущенную выборку

$$\theta \sim p(\theta \mid |x_o - x| < \varepsilon) \iff \exists i \in 1, \dots, n : \theta = \theta_i + \xi, \quad \xi \sim \mathcal{N}(0, \Sigma)$$

После этого, для всех таких θ мы уже гарантированно будем иметь $|x_o - x| < \varepsilon$, поэтому чтобы увеличить точность, можно взять $\varepsilon_1 < \varepsilon_0 = \varepsilon$ и проделать те же действия для него. Примерно таким образом устроены последовательные алгоритмы SMC-ABC (Sequential Monte-Carlo ABC, [?]) и PMC-ABC (Population Monte-Carlo, [?]).

Эту идею также развили и для NPE методов, так появились NPE-A,B,C, Truncated-NPE и др. ([?, ?, ?, ?]).

3.1. **NPE-A,B,C.**

3.2. **Truncated.**

Естественно, при этом теряется амортизированность этих методов, но это оправдано постановкой задачи — нам нужно узнать апостериор только для одного наблюдения.

4. Основные результаты

В этом разделе мы приведем описание и результаты работы алгоритма на нескольких классических моделях

4.1. **Gaussian Mixture.**

4.2. **SIR.**

Здесь мы рассмотрим модель распространения заболевания SIR (Suspectable-Infected-Recovered) Она устроена следующим образом. В каждый момент времени состояние описывается тремя числами S, I, R - которые означают число людей из соответстующей категории (S - Здоровые, I - Больные, R - Переболевшие). Всегда выполнено соотношение $S + I + R = N$ - общее число людей, а динамика задается так

$$\begin{cases} S_{t+1} = S_t - \Delta_{inf} \\ I_{t+1} = I_t + \Delta_{inf} - \Delta_{rec} \\ R_{t+1} = R_t + \Delta_{rec} \end{cases}$$

где $\Delta_{inf} \sim Binomial(S, 1 - e^{-\beta \frac{I}{N}}), \Delta_{rec} \sim Binomial(I, 1 - e^{-\gamma})$. Здесь β, γ — искомые параметры $\theta \in \mathbb{R}^2$, а $x \in \mathbb{R}^5$ — вектор саммари-статистик, полученный из временного ряда $(S_t, I_t, R_t) \in \mathbb{R}^{T \times 3}$

4.3. **Модель Хестона.**

Модель Хестона стохастической волатильности описывается стохастическим дифференциальным уравнением

$$blah - blah$$

В рамках задачи, мы воспринимаем его как следующую процедуру генерации

алгоритм

Искомыми параметрами здесь являются μ — , σ —, ϕ —, m — . В качестве наблюдений мы используем выход последнего скрытого слоя реккурентной нейросети, запущенной на временном ряде цены актива. Эта сеть обучается вместе с векторным полем.

5. Послесловие

Здесь можно сформулировать основные определения из рассматриваемой области. Ниже приведен шуточный пример.

Работа посвящена изучению очень крутой задачи о сипульках, которая изучалась, например, в работах [1, 2]. Сипульки естественным образом появляются при изучении кантовских множеств и энгельсовских групп, которые в свою очередь играют огромную роль в теоретической экономике. Приведем основные определения.

Определение 1. Фигулькой называется элемент кантовского множества, на котором действует энгельсовская группа.

Определение 2. Сипулькой называются фигулька, удовлетворяющая условиям Смита–Сидорова.

В своей основополагающей статье [1] К.Л.Ассик ввел эти определения и показал, как эти понятия применяются в теоретической экономике. Первое фундаментальное исследование сипулек было опубликовано в книге [3]. После этого долгое время никто не мог получить новых результатов в рассматриваемой области, пока в статье [2] автор не доказал существование фигулек, не являющихся сипульками. Также в этой статье была сформулирована следующая гипотеза.

Гипотеза 1 (С.О.Временник)**.** *Для того чтобы фигулька являлась сипулькой достаточно выполнения первого условия Смита, а условия Сидорова тут вообще ни при чем.*

Эта гипотеза была доказана в трех статьях китайских авторов и опровергнута в одной статье индийского товарища. К сожалению, все эти статьи содержат неисправимые ошибки.

6. Формулировка основных результатов

Мы планируем доказать слабую форму гипотезы С.О.Временника, а именно следущий результат.

Теорема 3. *Все хорошие фигульки являются сипульками.*

Этот результат явился бы первым подтверждением гипотезы С.О.Временника, в которую в настоящий момент кроме моего научного руководителя никто не верит.

7. Методы доказательства

Для доказательства теоремы 3 мы планируем использовать как методы теории групп, так и более специфические методы функционального анализа, развитые в работе [2]. Точнее. . . . . (далее излагается план доказательства, который вам поведал научный руководитель).

Названия параграфов, как и общий смысл отчета, не обязаны совпадать с этим шаблоном.

Список литературы

[1] C. L. Assic, *The main properties of sipulki*, Main J. Math. **1** (1900), №1, 1–100.
[2] С. О. Временник, *Новые потрясающие свойства сипулек*, Российский мат. ж. **666** (2021), №1, 998–1000.
[3] И. И. Сидоров, *Большая книга о сипульках*, изд-во Мир, Москва, 1962.