

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
“САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ”
(СПбГУ)

Образовательная программа бакалавриата “Математика”



Отчет о практике
на тему
Sequential модификация метода Flow Matching Posterior Estimation

Выполнил студент 2 курса бакалавриата
группа 24.Б03-мкн
Ураков Михаил Алексеевич

Научный руководитель:
Должность, ФИО

Санкт-Петербург
2026

СОДЕРЖАНИЕ

1. Введение	3
2. Flow Matching	4
2.1. Ключевая идея Flow Matching	6
2.2. Условная формулировка	6
2.3. Пример	6
2.4. Теорема о совпадении лоссов	7
3. Последовательные методы	8
3.1. Постановка задачи и общая схема	8
4. Основные результаты	11
5. Послесловие	11

1. ВВЕДЕНИЕ

Задача оценки истинных параметров математической модели встречается во многих научных и прикладных областях: генетике [fast-eps-source], физике [DINGO-source], финансах и др. Она становится особенно сложной, когда невозможно аналитически описать распределение наблюдений при заданных параметрах. В этой работе мы, следуя статье [DINGO-source], предлагаем модификацию метода Flow Matching Posterior Estimation и сравниваем его с другими методами на простых задачах, а в конце применим его для оценки параметров модели стохастической волатильности.

С математической точки зрения наша задача формулируется следующим образом. Будем обозначать $\theta \in \mathbb{R}^m$ — вектор параметров модели, а $x \in \mathbb{R}^n$ — наблюдаемые/симулированные данные или, чаще, их малоразмерная аппроксимация, выжимка. Из-за стохастической природы моделей удобно считать как x , так и θ случайными величинами.

Далее, нам известно, возможно неявно, *правдоподобие* $p(x | \theta)$ — распределение наблюдений x , которые мы можем получить при условии, что модель инициализирована параметрами θ . Также мы имеем вольность задать *априорное* распределение $p(\theta)$ — наше общее представление о том, в каких пределах могут изменяться параметры модели.

Имея все это, мы хотим узнать *апостериорное* распределение $p(\theta | x)$ — распределение параметров, которые могли бы дать нам такое же наблюдение x . Тогда по формуле байеса имеем

$$p(\theta | x) = \frac{p(x | \theta)p(\theta)}{p(x)}$$

Markov Chain Monte Carlo. Таким образом, коль скоро нам известны $p(x | \theta), p(\theta)$, можно считать, что $p(\theta | x) \propto p(x | \theta)p(\theta)$. Если бы мы имели аналитическое выражение для последнего, то могли бы сэмплировать из апостериорного распределения методами Markov Chain Monte Carlo (MCMC, [?]). Их суть заключается в том, чтобы построить марковскую цепь, стационарное распределение которой будет совпадать с заданным. Тогда, пройдя по ней достаточное число шагов, мы получим выборку из нужного распределения.

Помимо того, что нам нужно знать явное выражение для ненормированной плотности, у этого метода есть другие минусы, такие как: вычислительная затратность, сложность диагностики сходимости, чувствительность к настройкам и проблемы в больших размерностях.

Approximate Bayesian Computation. В случае когда мы не можем аналитически выразить правдоподобие, приходится действовать другими методами. В литературе их объединяют под общим названием ABC (Approximate Bayesian Computation [?]) методов. Классические алгоритмы ABC основаны на предположении о том, что если наблюдения похожи, то и соответствующие параметры тоже. Более формально, они аппроксимируют истинное апостериорное $p(\theta | x_o)$ с помощью $p(\theta | |x_o - x| < \varepsilon)$

Самый простой метод, Rejection ABC, работает так:

- (1) Дано: наблюдение x_o , хотим получить выборку из $p(\theta | x_o)$
- (2) Генерируем $\theta^* \sim p(\theta)$
- (3) Симулируем $x \sim p(x | \theta^*)$
- (4) Если $|x_o - x| < \varepsilon$, то добавляем θ^* в выборку, иначе повторить 2.

Из очевидных минусов — это проклятие размерности и неэффективность вычислений. Для вычисления апостериора только в одной точке x_o нам требуется провести тысячи

симуляций, большая часть из которых будет отмечена, причем с увеличением разменности это число растет экспоненциально.

Neural Posterior Estimation. В последние годы, с развитием машинного обучения, пришли и новые методы оценки апостериора. В отличие от классических алгоритмов, где апостериор вычислялся только эмпирически, методы NPE (Neural Posterior Estimation, [?]) позволяют аппроксимировать функцию плотности с помощью нейросети. Часто в качестве универсального аппроксиматора используют *нормализующие потоки* (Normalizing Flows, [?]), хорошо показавшие себя в задачах физики гравитационных волн [?]. Нормализующие потоки отображают сэмплы из одного (обычно, гауссовского) распределения в другое распределение серией последовательных несложных преобразований, параметризованных нейросетью.

Минус такого подхода в том, что эти преобразования должны быть обратимы и иметь определенный вид чтобы сеть можно было эффективно обучать. К тому же, такая архитектура плохо масштабируема для нужд больших и сложных экспериментов.

Однако, самый большой и главный плюс в сравнении с классическими методами — это то, что теперь, у нас на выходе не просто выборка из нужного распределения, а функция, которая каждому наблюдению x сопоставляет распределение $p(\theta | x)$. Таким образом, один раз обучив такую модель, мы получим $p(\theta | x)$ для всех возможных x , а не только одного — в литературе это называется амортизированным инференсом (Amortized Inference, [?]).

В контексте отображения одного распределения в другое эта задача родственна задаче генеративного ИИ. А в последние годы, в этой области доминируют диффузионные модели [?]. Принцип их работы основан на том же преобразовании одного распределения в другое, только теперь сэмплы двигаются по траекториям, которые являются решениями СДУ, заданного векторным полем. И нейросетью здесь параметризовано это самое поле.

Детерминированным аналогом диффузионных моделей являются Flow Matching модели [?]. В данном случае, вместо стохастического дифференциального уравнения используется обыкновенное. На них мы и сосредоточимся в этой работе.

2. FLOW MATCHING

Я изложу основные идеи метода Flow Matching и приведу доказательства некоторых утверждений Пусть:

- $p_0(x)$ — простое распределение (например, $\mathcal{N}(0, I)$),
- $p_1(x)$ — целевое распределение данных.

Задача: построить диффеоморфизм

$$\psi_1 : \mathbb{R}^d \rightarrow \mathbb{R}^d,$$

такой что

$$p_1(x) = [\psi_1]_{\#} p_0(x) = p_0(\psi_1^{-1}(x)) |\partial_x \psi_1^{-1}(x)|$$

Т.е. $X_1 = \psi_1(X_0) \sim p_1 \iff X_0 \sim p_0$. Вместо того, чтобы строить ψ_1 напрямую, рассмотрим векторное поле

$$\frac{d}{dt} \psi_t(x) = v_t(\psi_t(x)), \quad t \in [0, 1].$$

Из которого отображение ψ_1 восстанавливается интегрированием

$$\psi_1(x) = p_0(x) + \int_0^1 v_t(\psi_t(x)) dt$$

TODO: добавить теорему о существовании и единственности такого векторного поля
из 2412.06264v1

Теорема 1.

Предложение 1. Если ψ_t удовлетворяет

$$\frac{d}{dt} \psi_t(x) = v_t(\psi_t(x)),$$

то плотность $p_t = [\psi_t]_{\#} p_0(x)$ удовлетворяет уравнению непрерывности:

$$\partial_t p_t(x) + \nabla \cdot (p_t(x) v_t(x)) = 0.$$

Тогда, если мы найдём правильное v_t , то ψ_t хорошим образом перенесёт p_0 в p_1

Доказательство. Поскольку $\rho_t(y)$ определено как

$$\rho_t(y) = (\psi_t)_{\#} \rho_0(y) = \rho_0(\psi_t^{-1}(y)) |\det \partial_y \psi_t^{-1}(y)|$$

то

$$\int \varphi(y) \rho_t(y) dy = \int \varphi(\psi_t(x)) \rho_0(x) dx \quad \forall \varphi \in C_c^\infty.$$

Продифференцируем обе части по t :

$$\begin{aligned} \frac{d}{dt} \int \varphi(\psi_t(x)) \rho_0(x) dx &= \int \frac{d}{dt} \varphi(\psi_t(x)) \rho_0(x) dx \\ \frac{d}{dt} \varphi(\psi_t(x)) &= \nabla \varphi(\psi_t(x)) \cdot \dot{\psi}_t(x). \end{aligned}$$

И т.к.

$$\dot{\psi}_t(x) = u_t(\psi_t(x)),$$

получим

$$\frac{d}{dt} \int \varphi(\psi_t(x)) \rho_0(x) dx = \int \nabla \varphi(\psi_t(x)) \cdot u_t(\psi_t(x)) \rho_0(x) dx$$

Снова, по определению $\rho_t(y)$

$$\int \nabla \varphi(\psi_t(x)) \cdot u_t(\psi_t(x)) \rho_0(x) dx = \int \nabla \varphi(y) \cdot u_t(y) \rho_t(y) dy$$

Интегрированием по частям получим

$$\int \nabla \varphi \cdot u_t \rho_t = - \int \varphi \nabla \cdot (\rho_t u_t)$$

Тогда

$$\frac{d}{dt} \int \varphi \rho_t + \int \varphi \nabla \cdot (\rho_t u_t) = 0$$

И поскольку это выполнено для всех φ , то

$$\partial_t \rho_t + \nabla \cdot (\rho_t u_t) = 0$$

в слабом смысле

□

2.1. Ключевая идея Flow Matching.

Вместо обучения напрямую распределения $q_\theta(x) \approx p_1(x)$ через KL-дивергенцию, Flow Matching предлагает:

- (1) Задать интерполирующее распределение p_t между p_0 и p_1
- (2) Вычислить соответствующее *истинное* поле скоростей $u_t(x)$.
- (3) Обучать модель v_θ по регрессии:

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{t \sim U[0,1], x \sim p_t} \|v_t^\theta(x) - u_t(x)\|^2.$$

Проблема лишь в том, что *истинное* поле $u_t(x)$ нам обычно неизвестно.

2.2. Условная формулировка.

Тогда, вместо маргинального поля $u_t(x)$ введем условное поле

$$u_t(x \mid z),$$

где z — латентная случайная величина (например, пара $z = (x_0, x_1) \sim \pi_{0,1}$). Тогда условный лосс:

$$\mathcal{L}_{\text{cond}} = \mathbb{E}_{t, z, x_t \sim p_{1|z}(\cdot|z)} \|v_t^\theta(x_t) - u_t(x_t \mid z)\|^2.$$

И это легко сэмплировать:

- (1) берём z ,
- (2) генерируем $x_t \sim p_{1|z}$,
- (3) знаем $u_t(x_t \mid z)$ аналитически

В таком случае истинное поле выражается как

$$u_t(x) = \mathbb{E}_{z \sim \pi} [u_t(X_t \mid z) \mid X_t = x].$$

2.3. Пример.

Простейший случай с двумя гауссианами

$$\begin{aligned} p_0(x) &= \mathcal{N}(\mu_0, \sigma_0) \\ p_1(x) &= \mathcal{N}(\mu_1, \sigma_1) \\ \psi_{t|1}(x \mid x_1) &= tx_1 + (1-t)x \end{aligned}$$

Тогда условное поле скоростей:

$$u_{t|1}(x \mid x_1) = \dot{\psi}_{t|1} \circ \psi_{t|1}^{-1}(x \mid x_1) = \frac{x_1 - x}{1 - t}$$

И условный probability path:

$$\begin{aligned} p_{t|1}(x \mid x_1) &= p_{0|1}(\psi_{t|1}^{-1}(x \mid x_1)) |\partial_x \psi_{t|1}^{-1}(x \mid x_1)| = \\ &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \left(\frac{x - tx_1}{\sigma_0} \right)^2} \cdot \frac{1}{1-t} = \mathcal{N}(tx_1 + (1-t)\mu_0, (1-t)\sigma_0) \end{aligned}$$

Тогда marginal probability path:

$$\begin{aligned}
 p_t(x) &= \int p_{t|1}(x|x_1)p_1(x_1)dx_1 = \\
 &= \int \mathcal{N}(tx_1 + (1-t)\mu_0, (1-t)\sigma_0) \mathcal{N}(\mu_1, \sigma_1)dx_1 = \\
 &= \mathcal{N}(t\mu_1 + (1-t)\mu_0, t^2\sigma_1 + (1-t)\sigma_0)
 \end{aligned}$$

Отсюда по формуле Байеса

$$p_{1|t}(x_1 | x) = \frac{p_{t|1}(x | x_1)p_1(x_1)}{p_t(x)} = \mathcal{N}(\mu_{1|t}(x), \sigma_{1|t}(x))$$

где

$$\mu_{1|t}(x) = \mu_1 + \frac{t\sigma_1(x - t\mu_1 - (1-t)\mu_0)}{t^2\sigma_1 + (1-t)\sigma_0}$$

$$\sigma_{1|t}(x) = \frac{\sigma_1(1-t)\sigma_0}{t^2\sigma_1 + (1-t)\sigma_0}$$

Итого, marginal velocity field:

$$\begin{aligned}
 u_t(x) &= \int u_{t|1}(x | x_1)p_{1|t}(x_1 | x)dx_1 = \\
 &= \mathbb{E}\left[\frac{X_1 - X_t}{1-t} \mid X_t = x\right] = \frac{1}{1-t}\mathbb{E}[X_1 \mid X_t = x] - \frac{x}{1-t} = \\
 &= \frac{\mu_{1|t}(x) - x}{1-t}
 \end{aligned}$$

2.4. Теорема о совпадении лоссов.

Теорема 2. [?]

Градиент условного лосса совпадает с градиентом маргинального лосса:

$$\nabla_{\theta}\mathcal{L}_{cond} = \nabla_{\theta}\mathcal{L}_{marg},$$

где

$$\mathcal{L}_{cond} = \mathbb{E}_{t, Z \sim \pi, X_t \sim p_{1|Z}} \|v_t^{\theta}(X_t) - u_t(X_t|Z)\|^2.$$

$$\mathcal{L}_{marg} = \mathbb{E}_{t, X_t \sim p_t} \|v_t^{\theta}(X_t) - u_t(X_t)\|^2$$

Доказательство. [?]

$$\begin{aligned}
\nabla_{\theta} \mathcal{L}_{\text{marg}} &= \nabla_{\theta} \mathbb{E}_{t, X_t} \|v_t^{\theta}(X_t) - u_t(X_t)\|^2 \\
&= \mathbb{E}_{t, X_t} \nabla_{\theta} \|v_t^{\theta}(X_t) - u_t(X_t)\|^2 \\
&= \mathbb{E}_{t, X_t} \nabla_{\theta} v_t^{\theta}(X_t) \nabla_{v_t^{\theta}} \|v_t^{\theta}(X_t) - u_t(X_t)\|^2 \\
&= \mathbb{E}_{t, X_t} \nabla_{\theta} v_t^{\theta}(X_t) \nabla_{v_t^{\theta}} \|v_t^{\theta}(X_t) - \mathbb{E}_{Z \sim p_{Z|t}}[u_t(X_t | Z)]\|^2 \\
&= \mathbb{E}_{t, X_t} \mathbb{E}_{Z \sim p_{Z|t}} \nabla_{\theta} v_t^{\theta}(X_t) \nabla_{v_t^{\theta}} \|v_t^{\theta}(X_t) - u_t(X_t | Z)\|^2 \\
&= \mathbb{E}_{t, X_t} \mathbb{E}_{Z \sim p_{Z|t}} \nabla_{\theta} \|v_t^{\theta}(X_t) - u_t(X_t | Z)\|^2 \\
&= \mathbb{E}_{t, X_t \sim p_t|Z, Z \sim \pi} \nabla_{\theta} \|v_t^{\theta}(X_t) - u_t(X_t | Z)\|^2 \\
&= \nabla_{\theta} \mathbb{E}_{t, X_t \sim p_t|Z, Z \sim \pi} \|v_t^{\theta}(X_t) - u_t(X_t | Z)\|^2 \\
&= \nabla_{\theta} \mathcal{L}_{\text{cond}}
\end{aligned}$$

□

3. ПОСЛЕДОВАТЕЛЬНЫЕ МЕТОДЫ

Зачастую, нам требуется не просто оценить апостериор для данного x , а сделать это хорошо и эффективно. В таком случае, в существующие методы можно ввести некоторые модификации. Например, для Rejection ABC после некоторого числа подходящих сэмплов, логично предположить, что все последующие будут находиться в пределах нынешней выборки $\{\theta_i\}_{i=1}^n$, т.е. распределение $p(\theta | |x_o - x| < \varepsilon)$ можно представить как возмущенную выборку

$$\theta \sim p(\theta | |x_o - x| < \varepsilon) \iff \exists i \in 1, \dots, n : \theta = \theta_i + \xi, \quad \xi \sim \mathcal{N}(0, \Sigma)$$

После этого, для всех таких θ мы уже гарантированно будем иметь $|x_o - x| < \varepsilon$, поэтому чтобы увеличить точность, можно взять $\varepsilon_1 < \varepsilon_0 = \varepsilon$ и проделать те же действия для него. Примерно таким образом устроены последовательные алгоритмы SMC-ABC (Sequential Monte-Carlo ABC, [?]) и PMC-ABC (Population Monte-Carlo, [?]).

Эту идею также развили и для NPE методов, так появились NPE-A,B,C, Truncated-NPE и др. ([?, ?, ?, ?]).

3.1. Постановка задачи и общая схема.

Последовательное уточнение апостериора. Цель: оценить $p(\theta | x_o) \propto p(\theta) p(x_o | \theta)$, имея только симулятор $p(x | \theta)$.

Общая схема Sequential NPE (раунд r):

- (1) Строим proposal $\tilde{p}_r(\theta)$ (обычно текущая оценка апостериора).
- (2) Генерируем датасет: $\theta_i \sim \tilde{p}_r(\theta)$, $x_i \sim p(x | \theta_i)$.
- (3) Обучаем модель $q_{\phi}(\theta | x)$ на этих данных.

Проблема: без коррекции $q_{\phi}(\theta | x)$ будет приближать $\tilde{p}_r(\theta | x)$, а не истинный апостериор $p(\theta | x)$.

Почему возникает смещение. Истинное апостериорное распределение:

$$p(\theta | x) = \frac{p(\theta)p(x | \theta)}{p(x)}$$

Условное распределение при сэмплировании из $\tilde{p}$:

$$\tilde{p}(\theta | x) = \frac{\tilde{p}(\theta)p(x | \theta)}{\tilde{p}(x)}$$

Отношение:

$$p(\theta | x) \propto \tilde{p}(\theta | x) \frac{p(\theta)\tilde{p}(x)}{\tilde{p}(\theta)p(x)}$$

Необходимо компенсировать фактор $\frac{p(\theta)\tilde{p}(x)}{\tilde{p}(\theta)p(x)}$

3.1.1. *SNPE-A (Papamakarios & Murray, 2016).*

Идея SNPE-A.

- Модель: смесь гауссиан (MDN)
- Proposal $\tilde{p}(\theta)$ — также смесь гауссиан
- Коррекция выполняется **после** обучения, аналитическим пересчётом компонент MDN

Обучение: минимизация KL-дивергенции относительно $\tilde{p}$:

$$\mathcal{L}(\phi) = -\mathbb{E}_{\theta, x \sim \tilde{p}(\theta)p(x|\theta)} [\log q_\phi(\theta | x)]$$

После обучения $q_\phi(\theta | x) \approx \tilde{p}(\theta | x)$.

Коррекция: для нового x_o компоненты смеси q_ϕ домножаются на $\frac{p(\theta)}{\tilde{p}(\theta)}$ и перенормируются, давая $p(\theta | x_o)$. Аналитическая формула возможна только для смесей гауссиан

Преимущества и недостатки SNPE-A.

3.1.2. *SNPE-B (Lueckmann et al., 2017).*

Идея SNPE-B. Использование importance weighting прямо в функции потерь:

$$\mathcal{L}(\phi) = -\mathbb{E}_{\theta, x \sim \tilde{p}(\theta)p(x|\theta)} \left[\frac{p(\theta)}{\tilde{p}(\theta)} \log q_\phi(\theta | x) \right]$$

Обоснование: минимизация этого среднего (с точностью до константы) эквивалентна минимизации расстояния до истинного апостериора, т.к.

$$\tilde{p}(\theta)p(x | \theta) \cdot \frac{p(\theta)}{\tilde{p}(\theta)} = p(\theta)p(x | \theta) \propto p(\theta | x).$$

- Допускает произвольные параметрические модели q_ϕ (не только смеси гауссиан)
- Требует вычисления плотности $\tilde{p}(\theta)$ (proposal) и $p(\theta)$

Преимущества и недостатки SNPE-B.

3.1.3. *SNPE-C (APT, Greenberg et al., 2019).*

АРТ.

- Не использует ни плотность proposal, ни importance weights
- Строит вспомогательную задачу классификации “правильная θ для данного x ”

Для батча $\{(\theta_k, x_k)\}_{k=1}^K$, где $\theta_k \sim \tilde{p}(\theta)$, $x_k \sim p(x | \theta_k)$:

$$\mathcal{L}(\phi) = -\frac{1}{K} \sum_{k=1}^K \log \tilde{q}_\phi(\theta_k | x_k) = -\frac{1}{K} \sum_{k=1}^K \log \frac{\frac{q_\phi(\theta_k | x_k)}{p(\theta_k)}}{\sum_{j=1}^K \frac{q_\phi(\theta_j | x_j)}{p(\theta_j)}}$$

Свойства АРТ. Интерпретация: в такой дискретной постановке сеть буквально учится отвечать на вопрос “какой из этих θ сгенерировал этот x ?”. Ответом является распределение $\tilde{q}_\phi$

- Никаких явных плотностей proposal (только значения q_ϕ)
- Совместим с любыми параметризациями, где можно вычислить $\log q_\phi(\theta | x)$

Ограничение: Может страдать от “утечки” (leakage): апостериор “вытекает” за пределы априора, особенно на ранних раундах

Преимущества и недостатки АРТ.

3.1.4. *Truncated SNPE.*

Усечённое предложение. Ключевая идея: выбрать proposal $\tilde{p}(\theta)$, пропорциональное априору на некотором множестве $\mathcal{S}$:

$$\tilde{p}(\theta) = \frac{p(\theta) \mathbf{1}_{\mathcal{S}}(\theta)}{Z_{\mathcal{S}}},$$

где $\mathcal{S}$ – область высокой апостериорной вероятности (например, усечённый текущий аппроксимированный апостериор) Тогда отношение $p(\theta)/\tilde{p}(\theta) = Z_{\mathcal{S}} = \text{const}$ внутри $\mathcal{S}$, и смещение исчезает:

$$\tilde{p}(\theta)p(x | \theta) \propto p(\theta)p(x | \theta) \quad \text{на } \mathcal{S}.$$

Обучение: обычный NPE на данных из $\tilde{p}$, без каких-либо весов или контрастивных членов

Как выбрать $\mathcal{S}$. Обычно $\tilde{p}(\theta)$ – это текущая оценка апостериора $q_{\phi_{\text{old}}}(\theta | x_o)$, усечённая до области, где она не превышает некоторого порога или просто обрезаемая по границам априора

- Простейший вариант: $\tilde{p}(\theta) \propto q_{\text{old}}(\theta | x_o) \cdot \mathbf{1}_{p(\theta) > 0}$
- Более аккуратно: усечение по гиперкубу или по квантилям q_{old}

Важно: так как $\tilde{p}(\theta)$ пропорциональна $p(\theta)$ внутри $\mathcal{S}$, смещение отсутствует по построению, и коррекция не нужна

Преимущества и недостатки Truncated SNPE.

Сводка методов.	Метод	Коррекция	Требования	Ограничения	Совместимость с FMPE
	SNPE-A	Аналитическая пост-обработка MoG	Только MoG-модели	Низкая гибкость	Нет (нужен $\log q$)
	SNPE-B	Важностные веса $\frac{p}{\tilde{p}}$	$\log \tilde{p}$ и $\log p$	Высокая дисперсия весов	Нет (нужен $\log q$)
	APT (SNPE-C)	Контрастивная потеря InfoNCE	$\log q_\phi(\theta x)$	Leakage, большие батчи	Нет (дорогой $\log q$)
	Truncated	Усечение proposal $\propto p$	Никаких	Выбор искажения на границах	$\mathcal{S}$, Да

Заключение.

- Все методы, кроме Truncated, в той или иной форме требуют быстрого вычисления логарифма плотности модели q_ϕ
- Для моделей без дешёвого $\log q$ (как FMPE) естественным выбором является Truncated Sequential NPE
- APT (SNPE-C) наиболее гибок и популярен для классических потоков, но не избавляет от $\log q_\phi$

Естественно, при этом теряется амортизированность этих методов, но это оправдано постановкой задачи — нам нужно узнать апостериор только для одного наблюдения.

4. ОСНОВНЫЕ РЕЗУЛЬТАТЫ

5. ПОСЛЕСЛОВИЕ