Sequential Neural Posterior Estimation. Resume.

SNPE-A, SNPE-B, SNPE-C (APT), Truncated SNPE

4 мая 2026 г.

Содержание

1. Постановка задачи и общая схема
2. SNPE-A (Papamakarios & Murray, 2016)
3. SNPE-B (Lueckmann et al., 2017)
4. SNPE-C (APT, Greenberg et al., 2019)
5. Truncated Sequential NPE
6. Сравнительная таблица

Последовательное уточнение апостериора

Цель: оценить $p(\theta \mid x_o) \propto p(\theta)\, p(x_o \mid \theta)$, имея только симулятор $p(x \mid \theta)$.

Общая схема Sequential NPE (раунд r):

1. Строим proposal $\tilde{p}_r(\theta)$ (обычно текущая оценка апостериора).
2. Генерируем датасет: $\theta_i \sim \tilde{p}_r(\theta)$, $x_i \sim p(x \mid \theta_i)$.
3. Обучаем модель $q_\phi(\theta \mid x)$ на этих данных.

Последовательное уточнение апостериора

Цель: оценить $p(\theta \mid x_o) \propto p(\theta)\, p(x_o \mid \theta)$, имея только симулятор $p(x \mid \theta)$.

Общая схема Sequential NPE (раунд r):

1. Строим proposal $\tilde{p}_r(\theta)$ (обычно текущая оценка апостериора).
2. Генерируем датасет: $\theta_i \sim \tilde{p}_r(\theta)$, $x_i \sim p(x \mid \theta_i)$.
3. Обучаем модель $q_\phi(\theta \mid x)$ на этих данных.

Проблема: без коррекции $q_\phi(\theta \mid x)$ будет приближать $\tilde{p}_r(\theta \mid x)$, а не истинный апостериор $p(\theta \mid x)$.

Почему возникает смещение

Истинное апостериорное распределение:

$$p(\theta \mid x) = \frac{p(\theta)p(x \mid \theta)}{p(x)}$$

Условное распределение при сэмплировании из $\tilde{p}$:

$$\tilde{p}(\theta \mid x) = \frac{\tilde{p}(\theta)p(x \mid \theta)}{\tilde{p}(x)}$$

Почему возникает смещение

Истинное апостериорное распределение:

$$p(\theta \mid x) = \frac{p(\theta)p(x \mid \theta)}{p(x)}$$

Условное распределение при сэмплировании из $\tilde{p}$:

$$\tilde{p}(\theta \mid x) = \frac{\tilde{p}(\theta)p(x \mid \theta)}{\tilde{p}(x)}$$

Отношение:

$$p(\theta \mid x) \;\propto\; \tilde{p}(\theta \mid x)\,\frac{p(\theta)\tilde{p}(x)}{\tilde{p}(\theta)p(x)}$$

Необходимо компенсировать фактор $\frac{p(\theta)\tilde{p}(x)}{\tilde{p}(\theta)p(x)}$

Почему возникает смещение

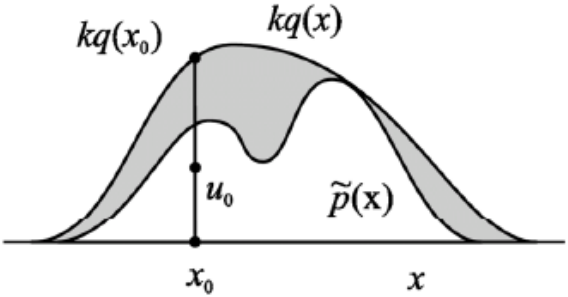

Идея SNPE-A

- Модель: смесь гауссиан (MDN)
- Proposal $\tilde{p}(\theta)$ — также смесь гауссиан
- Коррекция выполняется **после** обучения, аналитическим пересчётом компонент MDN

Идея SNPE-A

- Модель: смесь гауссиан (MDN)
- Proposal $\tilde{p}(\theta)$ — также смесь гауссиан
- Коррекция выполняется **после** обучения, аналитическим пересчётом компонент MDN

Обучение: минимизация KL-дивергенции относительно $\tilde{p}$:

$$\mathcal{L}(\phi) = -\mathbb{E}_{\theta, x \sim \tilde{p}(\theta) p(x|\theta)} \left[\log q_\phi(\theta \mid x) \right]$$

После обучения $q_\phi(\theta \mid x) \approx \tilde{p}(\theta \mid x)$.

Идея SNPE-A

- Модель: смесь гауссиан (MDN)
- Proposal $\tilde{p}(\theta)$ — также смесь гауссиан
- Коррекция выполняется **после** обучения, аналитическим пересчётом компонент MDN

Обучение: минимизация KL-дивергенции относительно $\tilde{p}$:

$$\mathcal{L}(\phi) = -\mathbb{E}_{\theta, x \sim \tilde{p}(\theta) p(x|\theta)} \left[\log q_\phi(\theta \mid x) \right]$$

После обучения $q_\phi(\theta \mid x) \approx \tilde{p}(\theta \mid x)$.

Коррекция: для нового x_o компоненты смеси q_ϕ домножаются на $\frac{p(\theta)}{\tilde{p}(\theta)}$ и перенормируются, давая $p(\theta \mid x_o)$. Аналитическая формула возможна только для смесей гауссиан

Преимущества и недостатки SNPE-A

Преимущества

- Простота реализации
- Нет проблем с высокой дисперсией весов

Преимущества и недостатки SNPE-A

Преимущества

- Простота реализации
- Нет проблем с высокой дисперсией весов

Недостатки

- Жёсткое ограничение: и $\tilde{p}$, и q_ϕ должны быть смесями гауссиан
- Негибкость для сложных многомодальных апостериоров
- Не подходит для моделей вроде нормализующих потоков

Идея SNPE-B

Использование importance weighting прямо в функции потерь:

$$\mathcal{L}(\phi) = -\mathbb{E}_{\theta, x \sim \tilde{p}(\theta) p(x|\theta)} \left[\frac{p(\theta)}{\tilde{p}(\theta)} \log q_\phi(\theta \mid x) \right]$$

Идея SNPE-B

Использование importance weighting прямо в функции потерь:

$$\mathcal{L}(\phi) = -\mathbb{E}_{\theta, x \sim \tilde{p}(\theta) p(x|\theta)} \left[\frac{p(\theta)}{\tilde{p}(\theta)} \log q_\phi(\theta \mid x) \right]$$

Обоснование: минимизация этого среднего (с точностью до константы) эквивалентна минимизации расстояния до истинного апостериора, т.к.

$$\tilde{p}(\theta) p(x \mid \theta) \cdot \frac{p(\theta)}{\tilde{p}(\theta)} = p(\theta) p(x \mid \theta) \propto p(\theta \mid x).$$

Идея SNPE-B

Использование importance weighting прямо в функции потерь:

$$\mathcal{L}(\phi) = -\mathbb{E}_{\theta, x \sim \tilde{p}(\theta) p(x|\theta)} \left[\frac{p(\theta)}{\tilde{p}(\theta)} \log q_\phi(\theta \mid x) \right]$$

Обоснование: минимизация этого среднего (с точностью до константы) эквивалентна минимизации расстояния до истинного апостериора, т.к.

$$\tilde{p}(\theta) p(x \mid \theta) \cdot \frac{p(\theta)}{\tilde{p}(\theta)} = p(\theta) p(x \mid \theta) \propto p(\theta \mid x).$$

- Допускает произвольные параметрические модели q_ϕ (не только смеси гауссиан)
- Требует вычисления плотности $\tilde{p}(\theta)$ (proposal) и $p(\theta)$

Преимущества и недостатки SNPE-B

Преимущества

- Гибкость: можно использовать любую модель для вычисления плотности (нормализующие потоки и пр.)

Преимущества и недостатки SNPE-B

Преимущества

- Гибкость: можно использовать любую модель для вычисления плотности (нормализующие потоки и пр.)

Недостатки

- Веса $w(\theta) = p(\theta)/\tilde{p}(\theta)$ могут иметь огромную дисперсию, особенно на ранних раундах
- Нестабильность обучения, медленная сходимость

APT

- Не использует ни плотность proposal, ни importance weights
- Строит вспомогательную задачу классификации “правильная θ для данного x”

APT

- Не использует ни плотность proposal, ни importance weights
- Строит вспомогательную задачу классификации “правильная θ для данного x”

Для батча $\{(\theta_k, x_k)\}_{k=1}^K$, где $\theta_k \sim \tilde{p}(\theta)$, $x_k \sim p(x \mid \theta_k)$:

$$\mathcal{L}(\phi) = -\frac{1}{K}\sum_{k=1}^{K} \log \tilde{q}_\phi(\theta_k \mid x_k) = -\frac{1}{K}\sum_{k=1}^{K} \log \frac{\frac{q_\phi(\theta_k|x_k)}{p(\theta_k)}}{\sum_{j=1}^{K} \frac{q_\phi(\theta_j|x_j)}{p(\theta_j)}}$$

Свойства АРТ

Интерпретация: в такой дискретной постановке сеть буквально учится отвечать на вопрос "какой из этих θ сгенерировал этот x?". Ответом является распределение $\tilde{q}_\phi$

Свойства APT

Интерпретация: в такой дискретной постановке сеть буквально учится отвечать на вопрос "какой из этих θ сгенерировал этот x?". Ответом является распределение $\tilde{q}_\phi$

- Никаких явных плотностей proposal (только значения q_ϕ)
- Совместим с любыми параметризациями, где можно вычислить $\log q_\phi(\theta \mid x)$

Свойства APT

Интерпретация: в такой дискретной постановке сеть буквально учится отвечать на вопрос "какой из этих θ сгенерировал этот x?". Ответом является распределение $\tilde{q}_\phi$

- Никаких явных плотностей proposal (только значения q_ϕ)
- Совместим с любыми параметризациями, где можно вычислить $\log q_\phi(\theta \mid x)$

Ограничение

- Может страдать от **“утечки” (leakage)**: апостериор “вытекает” за пределы априора, особенно на ранних раундах

Преимущества и недостатки APT

Преимущества

- Нет проблем с дисперсией весов
- Не требуется плотность $\tilde{p}(\theta)$, что позволяет легко менять proposal
- Хорошо работает с современными архитектурами

Преимущества и недостатки APT

Преимущества

- Нет проблем с дисперсией весов
- Не требуется плотность $\tilde{p}(\theta)$, что позволяет легко менять proposal
- Хорошо работает с современными архитектурами

Недостатки

- Требует вычисления $\log q_\phi(\theta \mid x)$ (для FMPE – дорого)
- Leakage: может потребоваться дополнительная регуляризация

Усечённое предложение

Ключевая идея: выбрать proposal $\tilde{p}(\theta)$, пропорциональное априору на некотором множестве $\mathcal{S}$:

$$\tilde{p}(\theta) = \frac{p(\theta)\,1_{\mathcal{S}}(\theta)}{Z_{\mathcal{S}}},$$

где $\mathcal{S}$ – область высокой апостериорной вероятности (например, усечённый текущий аппроксимированный апостериор)

Усечённое предложение

Ключевая идея: выбрать proposal $\tilde{p}(\theta)$, пропорциональное априору на некотором множестве $\mathcal{S}$:

$$\tilde{p}(\theta) = \frac{p(\theta)\,1_{\mathcal{S}}(\theta)}{Z_{\mathcal{S}}},$$

где $\mathcal{S}$ – область высокой апостериорной вероятности (например, усечённый текущий аппроксимированный апостериор) Тогда отношение $p(\theta)/\tilde{p}(\theta) = Z_{\mathcal{S}} = \text{const}$ внутри $\mathcal{S}$, и смещение исчезает:

$$\tilde{p}(\theta)p(x \mid \theta) \propto p(\theta)p(x \mid \theta) \quad \text{на } \mathcal{S}.$$

Усечённое предложение

Ключевая идея: выбрать proposal $\tilde{p}(\theta)$, пропорциональное априору на некотором множестве $\mathcal{S}$:

$$\tilde{p}(\theta) = \frac{p(\theta)\,1_{\mathcal{S}}(\theta)}{Z_{\mathcal{S}}},$$

где $\mathcal{S}$ – область высокой апостериорной вероятности (например, усечённый текущий аппроксимированный апостериор) Тогда отношение $p(\theta)/\tilde{p}(\theta) = Z_{\mathcal{S}} = \text{const}$ внутри $\mathcal{S}$, и смещение исчезает:

$$\tilde{p}(\theta)p(x \mid \theta) \propto p(\theta)p(x \mid \theta) \quad \text{на } \mathcal{S}.$$

Обучение: обычный NPE на данных из $\tilde{p}$, без каких-либо весов или контрастивных членов

Как выбрать $\mathcal{S}$

Обычно $\tilde{p}(\theta)$ – это текущая оценка апостериора $q_{\phi_{\text{old}}}(\theta \mid x_o)$, усечённая до области, где она не превышает некоторого порога или просто обрезанная по границам априора

Как выбрать $\mathcal{S}$

Обычно $\tilde{p}(\theta)$ – это текущая оценка апостериора $q_{\phi_{\text{old}}}(\theta \mid x_o)$, усечённая до области, где она не превышает некоторого порога или просто обрезанная по границам априора

- Простейший вариант: $\tilde{p}(\theta) \propto q_{\text{old}}(\theta \mid x_o) \cdot 1_{p(\theta)>0}$
- Более аккуратно: усечение по гиперкубу или по квантилям q_{old}

Как выбрать $\mathcal{S}$

Обычно $\tilde{p}(\theta)$ – это текущая оценка апостериора $q_{\phi_{\text{old}}}(\theta \mid x_o)$, усечённая до области, где она не превышает некоторого порога или просто обрезанная по границам априора

- Простейший вариант: $\tilde{p}(\theta) \propto q_{\text{old}}(\theta \mid x_o) \cdot 1_{p(\theta)>0}$
- Более аккуратно: усечение по гиперкубу или по квантилям q_{old}

Важно: так как $\tilde{p}(\theta)$ пропорциональна $p(\theta)$ внутри $\mathcal{S}$, смещение отсутствует по построению, и коррекция не нужна

Преимущества и недостатки Truncated SNPE

Преимущества

- Простота реализации
- Нет проблем с весами
- Гарантированно не выходит за границы априора (нет leakage)
- Идеально стыкуется с FMPE, где быстрый $\log q_\phi$ отсутствует

Преимущества и недостатки Truncated SNPE

Преимущества

- Простота реализации
- Нет проблем с весами
- Гарантированно не выходит за границы априора (нет leakage)
- Идеально стыкуется с FMPE, где быстрый $\log q_\phi$ отсутствует

Недостатки

- Если истинный апостериор сконцентрирован у границы априора, усечение может исказить форму
- Требует настройки параметров усечения (слишком узкое – потеря точности, слишком широкое – низкая эффективность)

Сводка методов

Метод	Коррекция	Требования	Ограничения	Совместимость с FMPE
SNPE-A	Аналитическая пост-обработка MoG	Только MoG-модели	Низкая гибкость	Нет (нужен log q)
SNPE-B	Важностные веса $\frac{p}{\tilde{p}}$	$\log \tilde{p}$ и $\log p$	Высокая дисперсия весов	Нет (нужен log q)
APT (SNPE-C)	Контрастивная потеря InfoNCE	$\log q_\phi(\theta \mid x)$	Leakage, большие батчи	Нет (дорогой log q)
Truncated	Усечение proposal $\propto p$	Никаких	Выбор $\mathcal{S}$, искажения на границах	**Да**

Заключение

- Все методы, кроме Truncated, в той или иной форме требуют быстрого вычисления логарифма плотности модели q_ϕ
- Для моделей без дешёвого $\log q$ (как FMPE) естественным выбором является Truncated Sequential NPE
- APT (SNPE-C) наиболее гибок и популярен для классических потоков, но не избавляет от $\log q_\phi$