Последовательные методы в Simulation-Based Inference

Применимость к FMPE, дрейф эмбеддинга и работа с данными

Обсуждение на форуме

2 мая 2026 г.

Содержание

1. Обзор последовательных SNPE методов
2. Особенности FMPE
3. Применимость SNPE к FMPE
4. Дрейф эмбеддинга в sequential NPE

Семейство Sequential Neural Posterior Estimation

Классические методы коррекции смещения, возникающего при итеративном сужении proposal:

- **SNPE-A** (Papamakarios & Murray, 2016) – точная коррекция для MoG.
- **SNPE-B** (Lueckmann et al., 2017) – взвешивание по важности.
- **SNPE-C / APT** (Greenberg et al., 2019) – контрастивная потеря (InfoNCE).
- **Truncated SNPE** (Deistler et al., 2022) – усечение proposal по априору.

Семейство Sequential Neural Posterior Estimation

Классические методы коррекции смещения, возникающего при итеративном сужении proposal:

- **SNPE-A** (Papamakarios & Murray, 2016) – точная коррекция для MoG.
- **SNPE-B** (Lueckmann et al., 2017) – взвешивание по важности.
- **SNPE-C / APT** (Greenberg et al., 2019) – контрастивная потеря (InfoNCE).
- **Truncated SNPE** (Deistler et al., 2022) – усечение proposal по априору.

Общая идея: на раунде t сэмплируем $\theta \sim \tilde{p}_t(\theta)$, генерируем x и обучаем $q_\phi(\theta|x)$, избегая смещения.

Что требуется от модели $q_\phi(\theta|x)$

Во всех SNPE нужно уметь:

- Сэмплировать $\theta \sim q_\phi(\theta|x_o)$ (proposal).
- **Но также считать** $\log q_\phi(\theta|x)$:
  - В SNPE-A/B – для коррекции смещения/весов.
  - В SNPE-C (APT) – для вычисления контрастивной потери InfoNCE.

Что требуется от модели $q_\phi(\theta|x)$

Во всех SNPE нужно уметь:

- Сэмплировать $\theta \sim q_\phi(\theta|x_o)$ (proposal).
- **Но также считать** $\log q_\phi(\theta|x)$:
  - В SNPE-A/B – для коррекции смещения/весов.
  - В SNPE-C (APT) – для вычисления контрастивной потери InfoNCE.

Таким образом, ключевое требование к параметрической модели – быстрый доступ к логарифму плотности.

Flow Matching Posterior Estimation

FMPE (Dax et al., 2023) – генеративная модель, основанная на Continuous Normalizing Flows.

- Позволяет сэмплировать из $q_\phi(\theta|x)$ очень быстро (прямое интегрирование ODE).
- Плотность $\log q_\phi(\theta|x)$ **существует**, но её вычисление требует обратного интегрирования ODE с расчётом следа якобиана – **дорого**.

Flow Matching Posterior Estimation

FMPE (Dax et al., 2023) – генеративная модель, основанная на Continuous Normalizing Flows.

- Позволяет сэмплировать из $q_\phi(\theta|x)$ очень быстро (прямое интегрирование ODE).
- Плотность $\log q_\phi(\theta|x)$ **существует**, но её вычисление требует обратного интегрирования ODE с расчётом следа якобиана – **дорого**.

Обучение FMPE идёт через Conditional Flow Matching (CFM) – нужны только сэмплы и векторное поле, **логарифм плотности не используется**.

Какие методы не подходят

- **SNPE-A** и **SNPE-B**: требуют $\log \tilde{p}(\theta)$ (плотности proposal) или $\log q_\phi(\theta|x)$ – для FMPE это вычислительный bottleneck.
- **SNPE-C (APT)**: вопреки интуиции, **тоже требует** $\log q_\phi(\theta|x)$ в потере InfoNCE:

$$\mathcal{L}_{\text{InfoNCE}} = -\frac{1}{K}\sum_{k=1}^{K} \log \frac{\exp(\log q_\phi(\theta_k|x_k))}{\sum_j \exp(\log q_\phi(\theta_j|x_k))}$$

Без быстрого логарифма обучение становится неэффективным.

Какие методы не подходят

- **SNPE-A** и **SNPE-B**: требуют $\log \tilde{p}(\theta)$ (плотности proposal) или $\log q_\phi(\theta|x)$ – для FMPE это вычислительный bottleneck.
- **SNPE-C (APT)**: вопреки интуиции, **тоже требует** $\log q_\phi(\theta|x)$ в потере InfoNCE:

$$\mathcal{L}_{\text{InfoNCE}} = -\frac{1}{K}\sum_{k=1}^{K} \log \frac{\exp(\log q_\phi(\theta_k|x_k))}{\sum_j \exp(\log q_\phi(\theta_j|x_k))}$$

Без быстрого логарифма обучение становится неэффективным.

Вывод: прямое применение классических SNPE к FMPE невозможно без потери ключевого преимущества.

Truncated Sequential NPE – единственный простой вариант

Метод Truncated (усечённый) не использует никаких явных плотностей:

- Proposal $\tilde{p}_t(\theta)$ обрезается до границ априора.
- Смещение отсутствует по построению, достаточно стандартной CFM-потери.

Truncated Sequential NPE – единственный простой вариант

Метод Truncated (усечённый) не использует никаких явных плотностей:

- Proposal $\tilde{p}_t(\theta)$ обрезается до границ априора.
- Смещение отсутствует по построению, достаточно стандартной CFM-потери.

Truncated FMPE:

1. Обучить FMPE на данных из априора (раунд 0).
2. Построить proposal = усечённый FMPE$(\cdot|x_o)$.
3. Сэмплировать из этого proposal, симулировать x, добавить в обучающую выборку.
4. Обучить FMPE заново или дообучить (с CFM-лоссом) на всех данных.
5. Повторить с шага 2 с новым proposal.

Никаких $\log q_\phi$ не требуется.

Перспективы других sequential подходов

Авторы FMPE упоминают, что sequential NPE к FMPE «применим, но оставлен на будущее». Вероятные пути:

- Использовать отдельный лёгкий суррогат для оценки $\log q_\phi$ (но вырастет сложность).
- Перейти к sequential Neural Ratio Estimation (не требует плотности модели).
- Разработать варианты APT с аппроксимацией $\log q_\phi$ без полного интегрирования ODE.

Пока Truncated FMPE – самый практичный выбор.

Проблема изменяющегося представления x_o

Если совместно с q_ϕ обучается summary-сеть h_ψ:

- На раунде t используется представление $h_{\psi_t}(x_o)$.
- При переходе к раунду $t+1$ веса ψ обновляются, и $h_{\psi_{t+1}}(x_o) \neq h_{\psi_t}(x_o)$.
- Proposal, основанный на старом представлении, становится несогласованным с новым.

Проблема изменяющегося представления x_o

Если совместно с q_ϕ обучается summary-сеть h_ψ:

- На раунде t используется представление $h_{\psi_t}(x_o)$.
- При переходе к раунду $t+1$ веса ψ обновляются, и $h_{\psi_{t+1}}(x_o) \neq h_{\psi_t}(x_o)$.
- Proposal, основанный на старом представлении, становится несогласованным с новым.

Это нарушает предположения sequential методов и может привести к смещению или расходимости.

Как решается в библиотеке sbi

Стратегия по умолчанию:

1. На первом раунде summary-сеть обучается вместе с плотностью.
2. Начиная со второго раунда, **веса summary-сети замораживаются**.
3. Пользователь может явно передать embedding_net в density_estimator, и sbi автоматически исключит её из оптимизатора после первого раунда.

Как решается в библиотеке sbi

Стратегия по умолчанию:

1. На первом раунде summary-сеть обучается вместе с плотностью.
2. Начиная со второго раунда, **веса summary-сети замораживаются**.
3. Пользователь может явно передать embedding_net в density_estimator, и sbi автоматически исключит её из оптимизатора после первого раунда.

Другие подходы:

- Предобучение эмбеддинга и полная заморозка с самого начала.
- Использование отдельного внешнего цикла для дообучения эмбеддинга (редко).